

Détection d'Alzheimer :  
Apprentissage profond vs Machine Learning classique  
Projet Kaggle — M2 BDIA

Votre Nom

Master 2 BDIA

December 5, 2025

# Problématique & Jeu de données

- ▶ **Objectif** : prédire si un individu est **sain** ou **atteint d'Alzheimer**.
- ▶ **Données** : un jeu Kaggle contenant des variables numériques anonymisées.
- ▶ Chaque ligne représente un patient, la dernière colonne = la cible.
- ▶ **Défis** :
  - Grande dimensionnalité.
  - Déséquilibre entre classes.
  - Nécessité d'un modèle fiable en contexte médical.

# Pipeline Machine Learning Classique

**Notebook ML** : SVM, Bagging, XGBoost, LightGBM, CatBoost, Stacking.

- ▶ **Division train/validation** avec `train_test_split`.
- ▶ **Exploration** :
  - Distribution des classes.
  - Analyse statistique des variables.
  - Sélection univariée via `SelectKBest`.
- ▶ **Réduction de dimension** :
  - PCA (`n_components = 80`).
  - Standardisation via `StandardScaler`.

# Modèles ML & Stacking

- ▶ Modèles utilisés :
  - Arbres de décision : XGBoost, LightGBM, CatBoost, ExtraTrees, RandomForest.
  - **Bagging** avec arbre de décision.
  - **SVM** (RBF, C=3).
- ▶ **StackingClassifier** :
  - Tous les modèles en base.
  - Méta-modèle : CatBoost.
  - Utilise `predict_proba` et `cv=10`.
- ▶ **Évaluation** :
  - Courbe ROC et AUC.
  - Analyse du compromis sensibilité / spécificité.

# Pourquoi Passer au Deep Learning ?

- ▶ Le stacking est performant mais :
  - Très complexe à entraîner.
  - Multiples hyperparamètres.
- ▶ L'apprentissage profond permet :
  - Un **modèle unique et end-to-end**.
  - Une meilleure capture des interactions non linéaires.
  - Une gestion plus fine du déséquilibre.
- ▶ Le second notebook implémente une **vraie pipeline Deep Learning**.

# Pipeline Deep Learning : Prétraitement

- ▶ **Division des données** : train / validation / test.
- ▶ **Standardisation** sur les données d'entraînement.
- ▶ **Sélection automatique de variables** :
  - Petit réseau dense avec régularisation L1.
  - Importance = poids absolus de la première couche.
  - Sélection des **45 meilleures variables**.

# Modèle Deep Learning

- ▶ Entrée : 45 variables sélectionnées et normalisées.
- ▶ **Architecture MLP** :
  - Plusieurs couches denses.
  - Régularisation et activations non linéaires.
- ▶ **Déséquilibre géré via** :
  - `class_weight` équilibré.
  - **Focal loss** pour accentuer les cas difficiles.
- ▶ **Optimisation** :
  - AdamW.
  - AUC comme métrique principale.
  - EarlyStopping + ReduceLROnPlateau.

# Évaluation du Modèle DL

- ▶ Sortie : probabilité d'être malade.
- ▶ **Courbe ROC** sur la validation.
- ▶ **Seuil optimal** choisi via le critère de Youden :

$$J = TPR - FPR$$

- ▶ Rapport de classification :
  - Rappel, précision, f1-score.
  - Analyse ciblée sur les patients.

# Prédiction sur les Données Test

- ▶ Application du pipeline complet :
  - Standardisation.
  - Sélection des 45 variables.
  - Prédiction des probabilités.
- ▶ Création du fichier `submission.csv`.

## Comparaison ML Classique vs Deep Learning

| Aspect         | ML Classique<br>(Stacking) | Deep Learning               |
|----------------|----------------------------|-----------------------------|
| Famille        | Plusieurs modèles          | Un seul modèle end-to-end   |
| Variables      | PCA (80 comps)             | Sélection DL (45 variables) |
| Déséquilibre   | Géré partiellement         | Focal loss + class weights  |
| Complexité     | Très élevée                | Pipeline plus simple        |
| Interprétation | Importance des arbres      | Importance L1 plus directe  |
| Déploiement    | Stack lourd                | Un seul modèle Keras        |

# Conclusion

- ▶ Deux approches testées :
  - Un **stacking ML** très performant.
  - Un **modèle DL** optimisé pour le déséquilibre.
- ▶ Le Deep Learning offre :
  - Une pipeline unifiée.
  - Une meilleure adaptation au cas médical.
- ▶ Pistes futures :
  - Optimisation des hyperparamètres DL.
  - Calibration des probabilités.